AI 应用调研(6): 模型与 Harness 适配决定 Agent 复杂任务成功率, Gemini Spark 付费用户渗透及应用场景, Meta Muse 开放式 Agent 产品策略与竞争优势

以下是专家观点：

Chris：有第三方测评指出，Argon 模型在 3D 和金融等专业领域表现较强，但在 Agent 能力方面较弱。如何看待这些测评结果？影响 Agent 能力的因素是什么？是模型基础能力的差距，还是 Agent 系统执行层面的差异?

专家：目前在 Large Model Arena 的 Agent 菜单 Leaderboard 上，有 6 个模型并列第一，其中包括 Argon。这 6 个模型的 Elo 分数并非完全一致，而是在置信区间内互相重叠，因此统计上属于并列第一。如果只看 point estimation，即准确的 Elo 分数，Argon 目前排在第四，低于 Opus 5.5、GPT SOL 6.1 和 Fiber 5.1 Max。如果看综合榜单，比如 Text 榜，涵盖 Authentic coding、聊天、搜索等多个维度，Argon 和 Muse 的 Wonder model 并列第一。因此，评价结果取决于是看置信区间还是具体分数。

Chris：影响 Agent 能力的核心因素是模型基础能力的差距，还是 Agent 系统执行层面的差异?

专家：目前并列第一的 6 个模型，对 Fable 5.1 Max、Opus 5.5 Max、Argon 以及其他新模型都做过详细评估。这些模型的主要差异不在于 Hallucination，而在于谁的响应速度更快、可读性更好。如果只比较模型 A 和 B 的体感测试，Hallucination 已经不是最关键的因素，这主要影响最终用户的体验。对于模型训练团队来说，评价指标通常是通过固定测试来衡量模型表现，但这些测试无法完全反映用户的实际感受。有时模型会输出一些奇怪的话，但只要最终结果达标，模型能理解并继续执行任务即可。

Agent 能力目前主要由四个方面决定。首先是预训练的方式，其次是后训练的方式，再者是与某种 Harness framework 的集成方式，即是 Harness 本身更复杂，还是模型端承

担更多 Harness 功能。最后一个重要因素是是否有额外的 validator，尤其是独有的 validator，可以在 Harness 中额外使用，这相当于一种“秘密武器”。例如，拥有许多 3D 相关的 validator，如 Blender 等，这类 validator 在 3D 任务中会显得非常独特。总体来看，这是一个综合性的因素。举个例子，测试过 Opus 5.5 和 OpenCode 的组合，即 Opus 5.5 加 OpenCode，仅更换 Harness，其他条件不变时，Opus 5.5 的分数会非常低。这说明 Opus 5.5 和 Claude Code 之间是深度绑定的。Antigravity 则比较有意思，无论搭配什么模型，最终得分都不高也不低，属于中性表现。目前，Argoon 结合效果最好的 Harness 是 OpenCode。因此，Agent 的表现好坏，很大程度上取决于与所选 Harness 的匹配程度。

Chris：怎么看 C 端 Personal AI Agent 的整体前景？目前重点似乎不在 C 端，是因为判断 B 端更有盈利前景和收入空间，还是说谷歌认为 Personal AI Agent 的市场空间有限？现在是因为算力紧缺无法分配资源，还是评估后认为 B 端投入更大？

专家：Spark 在 Gemini 内部是 P0 级别的项目，但 Spark 本身不是公司级别的重要项目，因此无法获得足够算力。还有一个有趣的现象，无论是否发布 Pro 模型，包括 Argon 模型，对 C 端 DAU 影响都不大，今年上半年 DAU 变化不明显。但发布 Flash 模型（如 3.7、3.8 Flash）后，DAU 有明显增长。现在不让大家用 Flash，只能用 Lite，DAU 反而下降。因此，阿港模型对 C 端 DAU 影响有限，C 端 DAU 与是否开放 Flash 模型高度相关。整体来看，模型是否 SOTA 与 C 端 DAU 关系不大。Personal Agent 目前无法获得足够算力。现在能与 Muse 竞争的主要是 Google Search，因为这两款产品设计都比较开放。比如 Muse 在界面验证人机身份时会自动处理，而 Gemini 不会帮你解答，需要用户自己操作。OpenAI 的 DALL-E 也能自动处理类似任务。产品设计上，Muse 非常开放，其实产品设计上，Muse 的开放性和激进性是其他公司难以比拟的。Anthropic 和 Google 目前都没有类似的基因去做这种极度开放的产品，OpenAI 相对也更保守。比如 Muse 允许免费用户直接打电话，并以用户身份自称，而 OpenAI 则会明确表明自己是 AI。这种设计导致 Muse 的接受度更高，产品设计上也更大胆，其他公司普遍不敢这样做。

Chris：如何看待 Agent 发挥价值的方式？在数据利用、用户隐私和权限管理方面会有哪些布局或规划？如何平衡这些问题？

专家：目前还没有特别有效的办法。以 Gemini Spark 为例，它的 DAU 渗透率还可以，是仅次于 Deep Research 的第二大付费用户功能。付费用户主要使用的 Top 几项功能，基本都与 Google 生态相关，如自动化 Google Drive、Gmail、Spreadsheet 等 SaaS 程序。对于 Google 生态内的用户，他们愿意为更好地利用生态内数据而付费。但像 Muse 这种纯开放生态的产品，Anthropic 和 Google 目前都没有类似的基因去做。OpenAI 也相对保守。Muse 在产品设计上非常激进，比如允许免费用户打电话时直接以用户身份自称，而 OpenAI 则会表明自己是 AI。这样 Muse 的接受度更高，产品设计也更大胆，其他公司普遍不敢这样做。知识星球：前沿信息收录　微信：FCCNNN88

Chris：最近调研 Meta Muse 产品时发现，其复杂任务的准确率也不理想。对于多步骤复杂任务，准确率往往较低。请问，如何提升多步骤任务的最终准确率和任务完成的可靠性？

专家：认为需要从多个方面入手。Muse 的准确率确实不高，有时访问一些网站时，数据查找也不准确。作为免费用户，感觉 Muse 没有为免费用户提供复杂的 Harness，因为这非常耗流量，每一步都需要截图和验证，Muse 可能没有做这些。但在更正式的场合，比如 Claude Code、Cursor、Antigravity、OpenCode 等，提高准确率的关键在于 Harness 的设计，或者让模型自身具备 Harness 能力，即模型本身更强，Harness 可以更轻。训练模型具备自我 Harness 和纠错能力非常重要。因此，通过各种预训练和后训练，把这类能力训练进模型，是提升准确率的关键。

Chris：如何评价 Meta 模型的性能或其 Harness 能力？

专家：个人也在用 Muse，感觉它没有做特别复杂的 Harness。有些明显的任务没有成功，比如访问自己生态内没问题，但我一直想让它访问小红书，帮我搜集热点或新闻调研，但始终无法成功，可能小红书也做了很多防御措施。不清楚收费用户是否体验更好，但 Muse 的 Harness 并不算很强，不像 OpenAI 的 Operator 那样做得很厚。这可能与成本

有关。GrokBot 是用过的收费产品，Harness 做得相当不错，主要面向 B 端 Use Case。用户群体也有差异，Meta Muse 用户多做一些跑腿类任务，甚至涉及灰色地带，比如叠加使用优惠券、打电话联系客服等，这些商家一般不会提供 API。GPT 和 Dost 更多用于小 B 端场景，如整理新闻、竞争对手信息等。GrokBot 作为收费产品，Harness 做得很不错，但用户群体不同，不能完全类比。

Chris：刚提到 SOTA 模型的发布对 C 端 DAU 影响不大。那么在 B 端，SOTA 模型对 API 使用量或收入有多大推动作用?

专家：如果从抢市场的角度看，SOTA 模型能抢占 Anthropic 或 Fable 的市场，Fable 本身又慢又贵。在大多数场合，Fable 和 Gemini 4 Argon 的区别不大，Argon 更快更便宜。Anthropic 和 Argon 相比，Argon 在 SaaS B 端场景有特殊训练和数据，因此能抢占原本属于其他 SOTA 模型的市场。但这块市场并不容易抢，因为很多企业在招标后选定 OpenAI 模型，产品就定型了。除非企业做新产品，否则迁移成本甚至高于初次开发成本。因此，To B 市场的抢占不会很快，这也是为什么大模型公司都在雇人做 FDE，推动自家模型尽快进入企业系统，这样未来企业更换模型的代价会很高。