纪要

主题: 世界模型与端侧AI访谈 时间: 2026-11-08 19:17:49 参与人: 前沿信息收录 V:FCCNN88

世界模型与端侧AI访谈

探讨技术路线、数据壁垒及商业化路径

基本信息

交流形式

专家访谈

核心议题

世界模型/物理AI/端侧硬件

核心洞察

卖数据比卖模型更具商业确定性；端侧算力受限于物理材料突破缓慢。

01. 观点脉络

技术未收敛 → 双路线并行 → 数据定壁垒

世界模型短期难有单一突破，实时交互与物理AI并行，高质量结构化数据的审美与生产能力成为核心壁垒。

算力受限 → 端侧瓶颈 → 以硬带软

端侧受限于物理材料导致参数量停滞，PICO等沉浸式硬件作为必要载体，通过硬件创新拉动软件生态落地。

02. 核心回答复盘

世界模型技术演进

Q 世界模型技术路线何时能实现收敛？

A 未来1-2年内难以形成单一技术突破，实时视频交互和物理AI大脑两条路线将持续并行投入。

Q 即将发布的模型是否包含严格的物理控制能力？

A 侧重实时视频生成与交互，类似Sora实时版，对物理设备控制能力较弱，真正的物理AI大脑更新可能延后。

数据供应链壁垒

Q 数据供应商的核心壁垒是什么？

A 在于数据的“审美”和持续生产能力，而非单纯的数据量或版权售卖；需具备影视工业背景的流程质检能力。

端侧硬件与算力

Q 端侧模型规模近两年是否有显著变化？

A 无显著变化，仍为3B-10B级别；受限于散热、续航等物理材料学突破缓慢，主要依赖基础模型能力提升。

Q 云端与端侧的任务分工边界在哪里？

A 隐私和安全相关任务在端侧闭环（约20%-30%意图识别），复杂仿真和统一策略由云端处理，考量延迟与体感。

商业化落地场景

Q 世界模型的商业模式如何闭环？

A 纯模型授权短期难盈利，转向应用场景分佣；数据服务和硬件销售是当前更确定的收入来源，“卖铲子”更赚钱。

03. 关键事实与限制

端侧物理限制

- 端侧AI上限受制于物理材料学突破速度
- 非单纯算法优化可解决
- 算力/功耗 > 内存 > 其他为核心卡点排序

底层硬件进步速度可能被市场高估

具身智能现状

- 人形机器人整体进度不快
- 轮式/低自由度设备在工业巡检已有应用
- 游戏/影视行业实时仿真落地较快，毛利可观

垂直场景落地优于通用机器人

04. 未回答与待确认

具身智能控制器厂商

专家研究较少，无法推荐具体公司

PICO出货量预测

不确定，采购和功能规划存在变数

AI生成可能有误，请注意核实细节

一句话概览

本次访谈围绕世界大模型的技术路线、物理AI数据供应链及端侧硬件落地展开；专家指出短期内“卖数据”比“卖模型”更具商业确定性，端侧算力受限于物理材料突破缓慢，PICO将作为世界模型的重要交互载体。

关键结论

- 技术收敛尚早：世界模型在未来1-2年内难以形成单一技术突破，实时视频交互与物理AI大脑两条路线将持续并行投入。
- 数据价值高于模型：当前阶段高质量结构化数据（如3D空间、动补数据）稀缺且采集成本高，数据供应商的壁垒在于数据审美与持续生产能力，而非单纯的数据售卖。
- 端侧算力瓶颈明显：受限于物理材料学（散热、续航），端侧模型参数量近两年无显著变化（仍为3B-10B级别），算力密度提升有限，主要依赖基础模型能力的增强。
- 商业化路径清晰：纯模型授权短期难盈利，商业模式更多转向应用场景分佣；PICO头显因具备沉浸式交互优势，将成为世界模型仿真的重要载体。

议题地图

- 世界模型技术演进：问题 1-3，讨论技术路线收敛时间、发布节奏及与物理AI的关系
- 数据供应链与壁垒：问题 4-5，探讨数据采集现状、供应商筛选标准及核心壁垒
- 端侧硬件与算力：问题 6-10，分析端侧模型规模、NPU要求、PICO新品及云边分工
- 商业化与落地场景：问题 11-13，讨论商业模式闭环、游戏/影视落地情况及竞争格局

完整问答

- 本场问答：访谈者：主持人/投资者；受访者：行业专家

- 问题 1：世界模型技术路线何时能实现收敛？未来主要的演绎方向是什么？

    - 核心回答：未来1-2年内难以形成单一技术突破，实时视频交互和物理AI大脑两条路线将持续并行。
    - 详细说明：
        - 目前技术路径未收敛，包括小参数交互、多维世界模拟（增加空间结构/3D）、实时仿真交互等方向均在投入。
        - 更关注能直接产生收益的“实时视频交互”，以及作为基座模型的“物理AI大脑”（已研发两年多，参数量300B-500B）。
        - 预计今年12月初发布连续自生成的世界模型（侧重实时交互），明年筹备10T参数的大模型以融合更多3D结构数据。

- 问题 2：即将发布的世界模型与物理AI有何区别？是否包含严格的物理控制能力？

    - 核心回答：12月发布的模型侧重实时视频生成与交互，并非严格意义上的物理AI模型，对物理设备控制能力较弱。

    - 详细说明：
        - 该模型类似Sora的实时版，可通过对话重构视频流程，但与物理现实交互关系不大。
        - 真正的物理AI大脑分支更新可能延后至12月底的原动力大会，目前空间结构和3D动补数据尚不完善，导致强交互效果一般。
        - 对于机器人操作等物理控制，目前难度较大，建议参考蚂蚁团队的相关论文。

- 问题 3：在物理AI和大模型的研发中，数据获取和质量保证是如何进行的？
    - 核心回答：数据供应商众多但良莠不齐，核心壁垒在于数据的“审美”和持续生产能力，而非单纯的数据量。
    - 详细说明：
        - 拥有约2000家数据供应商，大量通过横店等影视基地进行定向拍摄和绿幕录制，以获取高质量空间结构数据。
        - 多数供应商仅卖数据，缺乏数据Know-how和审美能力；更倾向于与具备影视工业背景的团队合作，以获得流程质检和校验输入。
        - 数据清洗、标注和审核的标准仍在完善中，单纯卖版权或一次性数据的价值较低。

- 问题 4：端侧AI今年的放量情况如何？是否有爆款单品出现？
    - 核心回答：端侧设备（如手环、戒指、AI家电）今年表现尚可，能产生收益，但未出现颠覆性体验的爆款。
    - 详细说明：
        - 端侧硬件在功耗、散热、续航上仍受限，复杂场景交互体验一般，目前更多是“玩具”或时尚单品属性。
        - 相比前两年，端侧模型效果有所提升，但算力密度受物理材料限制，综合体验差别不大。
        - PICO头显将结合12月发布的世界模型，提供沉浸式交互体验，是值得关注的新载体。

- 问题 5：目前端侧能稳定运行的模型规模是多少？对NPU算力和内存有何要求？
    - 核心回答：端侧模型规模近两年无显著变化，主要在3B-10B之间；算力需求取决于参数密度，FP8精度下1B模型约需1GB显存。
    - 详细说明：
        - 由于CPU、内存等物理硬件无核心突破，端侧承载的模型尺寸上限未变，主要依靠基础模型能力提升带来效果优化。
        - 计算密度较弱是工程上的主要问题，算力越大综合教育/交互效果越好。
        - PICO Space Pro目前使用高通SOC，后续可能引入国产方案，但具体节奏不确定。

- 问题 6：云端与端侧的任务分工边界在哪里？未来是否会向端侧倾斜？
    - 核心回答：参考阿里与苹果的合作模式，隐私和安全相关任务在端侧闭环，其他任务可

云端处理；端侧承担约20%-30%的意图识别。
    - 详细说明：
        - 端侧主要负责前置识别和本地隐私隔离，云端处理复杂仿真和统一策略，主要考量延迟和交互体感。
        - 随着端侧模型能力提升，部分功能会向端侧聚拢，但受限于算力密度和功耗，完全本地化处理长期存在困难。
        - 核心卡点排序：算力/功耗 > 内存 > 其他。

- 问题 7：PICO新品的核心变化是什么？自研芯片的进度如何？

    - 核心回答：PICO新品强化了端侧渲染和实时加速芯片方案，改善色彩成像和延时；云端自研芯片正在流片验证中。
    - 详细说明：
        - 针对云端推理、端侧渲染的模式，优化了读写和实时加速效果。
        - 云端训练芯片与高通、联发科合作进展顺利，自研通道（如博通设计）等待流片，三星6nm/4nm也在设计中。
        - 不会完全包圆端侧芯片，仍需依赖第三方IP和设计，以保持工程结构的合理性。

- 问题 8：世界模型和端侧AI的商业模式闭环是怎样的？

    - 核心回答：纯模型授权短期难盈利，主要靠应用场景分佣；数据服务和硬件销售是当前更确定的收入来源。
    - 详细说明：
        - 模型授权（License）在2024-2025年间较难卖出高价，用户付费意愿低。
        - 沉浸式短剧交互、游戏副本动态生成是确定的落地场景，可按效果分佣。
        - 真正赚钱的是“卖铲子”的人，即数据供应商和硬件厂商。

- 问题 9：具身智能控制器和人形机器人的落地情况如何？

    - 核心回答：专家对控制器环节研究有限，认为有价值但无法评判具体公司；人形机器人落地较慢，轮式/低自由度设备在工业巡检已有应用。
    - 详细说明：
        - 工业巡检、药房药检等垂直场景已有落地，但人形机器人整体进度不快。
        - 游戏和影视行业的实时仿真落地较快，竞争格局相对较好，毛利可观。

高价值表达

- 关于数据供应商的价值判断

    - 观点摘要：数据生意的核心壁垒不是资源垄断，而是对数据审美、标注策略和持续生产能力的理解。
    - 原文表达：好多公司可能最多就卖个版权...那有一些公司的话，可能能够从标注啊、清洗啊、审核啊、质检...我们觉得其实我们现在要的很多东西呢，一方面是对于主观的审美...再往些的话，可能就是在一些比如回归策略层面而言。

- 关于端侧AI的物理限制
    - 观点摘要：端侧AI的上限受制于物理材料学的突破速度，而非单纯的算法优化。
    - 原文表达：端侧AI因为受限于物理材料本身的变化...你能做的一些场景交汇的话，其实会有局限和一些上限...因为端测性能本身的这种材料的，就是或者算力是吧？这些受限。

未回答与待确认

- 具身智能控制器具体厂商：专家明确表示对该环节研究较少，无法推荐具体公司或评判标准。
- PICO具体出货量预测：专家表示不确定PICO能卖多少货，采购和功能规划存在不确定性。

AI洞察

- 专家反复强调“物理材料”和“数据结构”的硬约束，暗示当前AI热潮中，底层硬件和数据工程的进步速度可能被市场高估，算法层面的边际效应在递减。
- “卖数据比卖模型赚钱”的观点揭示了当前AI产业链的价值分布错位：上游数据基建的稀缺性和定制化能力尚未被充分定价，而中游模型层的同质化竞争已导致溢价能力下降。
- 将PICO定义为世界模型的“必要载体”而非单纯的游戏设备，表明大厂正在尝试通过硬件形态的创新来强行拉动软件生态的落地，这是一种典型的“以硬带软”战略。

章节

- 00:01:10 世界大模型技术路线与收敛判断
    - 专家指出世界模型技术路线尚未收敛，主要包含VRA交互、多维世界模拟及实时仿真交互三个方向。预计未来1-2年难有单一突破，但实时视频交互因能变现而受关注。字节侧重物理AI大脑研发，本体层面以合作为主。
- 00:06:54 发布节奏与数据供应链现状
    - 计划12月初发布连续自生成世界模型，年底筹备10T参数精模。当前高质量数据稀缺，数据供应商众多但缺乏持续生产能力和审美壁垒，字节正通过横店等渠道定向采集并加强与影视公司合作以提升数据质量。
- 00:23:29 端侧硬件放量与产品形态
    - 端侧AI今年在玩具、手环等设备上有一定放量，但受限于功耗、散热和算力密度，体验提升有限。PICO将作为沉浸式交互载体重新推广，眼镜类产品因缺乏突破性创新发布时间推迟。字节通过投资荣耀、努比亚等加强硬件合作。

- 00:37:00 端侧算力要求与云边分工
    - 端侧模型规模仍集中在3B-10B级别，NPU算力和内存带宽是瓶颈。云边分工参考阿里方案，约20%-30%涉及隐私和本地判定的任务在端侧处理，其余在云端。算力和续航是端侧核心卡点，自研芯片进度正常但完全包圆不现实。
- 00:49:06 商业模式与具身智能落地
    - 纯模型授权变现困难，短期机会在于卖硬件和数据服务（卖铲子）。具身智能控制器环节有价值但专家研究有限，工业巡检等垂直场景落地较快，人形机器人落地较慢。实时仿真在游戏、影视文旅领域已有应用且毛利较好。