纪要

主题: 超节点服务器产业现状与ODM盈利困境 时间: 2026-11-08 16:52:43 参与人: 前沿信息收录V:FCCNN88

超节点服务器产业现状与ODM盈利困境

围绕2026年超节点元年、CSP采购节奏及ODM厂商亏损报价的深度问答

基本信息

交流形式

专家访谈

核心议题

超节点服务器产业

核心洞察

利润集中在上游部件供应商和CSP，中游ODM沦为代工苦力，需贴钱换市场。

观点脉络

小批量验证 → 真正放量 → 产能瓶颈缓解

从2026年的头部客户导入验证，到2027年的大规模交付，最终在2028年随HBM/GPU产能释放实现供需平衡。

AVP模式锁定价格 → ODM仅赚加工费 → 普遍亏损报价

CSP通过指定供应商采购掌控核心部件定价权，导致ODM厂商在激烈竞争下不得不以低于成本5%-10%的价格竞标。

核心回答复盘

超节点产业节奏与客户分布

Q 目前超节点服务器在国内的整体状况如何？主要客户需求和技术迭代情况怎样？

A **2026年是超节点元年**，处于熟悉和验证期。需求主要由阿里、字节、腾讯牵引，阿里已发布磐久2.0并启动大规模招标，预计2027年初陆续交付。

Q 字节和腾讯在超节点方面的布局和采购情况如何？

A 字节采用自研推理芯片配合寒武纪训练芯片，首期交付约500柜；腾讯采用自有GPU方案，2026年招标约4000柜。两者均在2026年小规模验证，**大规模上量在2027年**。

整机柜性能优势与成本挑战

Q 超节点整机柜相比传统8卡/16卡服务器，在性能和成本上有何具体提升？

A 运行大模型业务时**性能提升30%-50%**，TCO显著优于传统架构。但存在故障率高、系统工程复杂的问题，单柜价格极高（千万级），目前主要适用于公共云业务。

ODM厂商的盈利困境与商业模式

Q 整机柜的运营成本相比以前有多大提升？ODM厂商的报价策略是怎样的？

A ODM厂商为争夺市场份额，**报价普遍低于核算成本5%-10%**，处于亏损状态。依靠政府补贴或其他业务弥补，如中兴有南京市政府补贴支持。

Q 超节点机柜中各组件的定价权归谁？ODM厂商的利润来源是什么？

A CSP采用**AVP（指定供应商采购）模式**，核心高价值部件（GPU、冷板等）价格由客户锁定。ODM仅能赚取加工费和低价值部件差价，导致整体报价亏损。

供应链瓶颈与技术演进方向

Q 明年超节点出货的节奏及限制因素有哪些？HBM和GPU供给情况如何？

A 主要制约因素是**HBM产能和国产GPU良率**。HBM依赖国外厂商，国产化进度慢；国产GPU产能有限。预计**2028年供需大幅缓解**。

Q 万卡集群的技术难点及未来技术演进方向是什么？

A 万卡集群技术上可行，但业务场景尚未完全需要。未来演进包括**800V高压供电**、液冷冷板升级、**硅光互联**以及带宽从112G向224G/448G演进。

市场结构与细分机会

推理需求远超训练

- 阿里今年采购约12万台8卡PCIe服务器全部用于**推理**
- 整机柜主要用于十万亿级大模型**训练**
- 推理一般用不到这么高端的配置

推理侧硬件需求量巨大，且NV存量优势依然坚固

信创市场格局

- 党政和运营商市场主要由**华为、海光、曙光**占据
- 对国产器件达标率有明确指标要求（如80%）
- 需求更多出于政治任务和验证，而非纯商业驱动

信创市场由头部国产厂商垄断，CSP增长前景更优

未回答与待确认

TCO具体节省数据	字节砍单比例	3D堆叠技术细节
仅表示“显著”，未提供百分比或金额	提及可能有砍单，但未给出具体数量	专家对寒武纪是否采用3D堆叠表示不了解

AI生成可能有误，请注意核实细节

一句话概览

本次问答围绕超节点服务器（Super Node）的产业现状、主要CSP厂商（阿里、字节、腾讯）的采购节奏与技术方案、ODM厂商的盈利模式及毛利率困境展开；专家明确指出2026年为超节点元年，目前处于小批量验证阶段，真正放量在2027年，且受限于HBM产能和GPU供应，ODM厂商在当前激烈竞争下普遍面临亏损报价。

关键结论

- 产业节奏：2026年是超节点元年，目前处于头部CSP客户小批量导入验证阶段，真正大批量交付和放量预计在2027年。
- 主要玩家与份额：国内超节点需求主要由阿里、字节、腾讯三家互联网巨头牵引；阿里磐久2.0招标4500柜，华勤、华信、浪潮、联想中标；字节自研推理芯片搭配寒武纪训练芯片；腾讯自有GPU方案招标约4000柜。
- 性能与成本优势：整机柜（64卡/128卡）相比传统8卡/16卡服务器，在运行大模型业务时性能提升30%~50%，TCO（总拥有成本）更优，但单柜价格极高（千万级），主要适用于公共云业务。
- ODM盈利困境：由于CSP厂商采用AVP（指定供应商采购）模式，核心高价值部件（GPU、冷板等）价格由客户锁定，ODM厂商仅能赚取加工费和低价值部件差价，导致报价普遍亏损5%~10%，依靠其他业务或政府补贴弥补。
- 技术瓶颈与演进：当前主要制约因素是HBM产能和国产GPU良率，预计2028年供需大幅缓解；技术演进方向包括800V高压供电、液冷冷板升级、硅光互联以及带宽从112G向224G/448G演进。
- 市场结构：推理需求远大于训练需求，阿里采购大量NV PCIe卡用于推理；党政信创市场主要由华为、海光、曙光占据，对国产化率有明确指标要求。

议题地图

- 超节点产业现状与客户分布：问题 1-3，讨论阿里、字节、腾讯的采购规模、技术方案及交付节奏
- 技术性能与成本分析：问题 4-6，对比整机柜与传统服务器的性能差异、TCO优势及故障率挑战
- ODM厂商商业模式与盈利：问题 7-9，解析AVP模式下的定价权归属、毛利率水平及亏损原因
- 供应链瓶颈与技术演进：问题 10-12，探讨HBM/GPU产能限制、未来技术路线（硅光、800V供电）及推理/训练比例
- 信创与细分市场机会：问题 13-14，分析党政运营商市场的需求特点及国产芯片现状

完整问答

- 本场问答：访谈者：主持人；受访者：行业专家

- 问题 1：目前超节点服务器在国内的整体状况如何？主要客户需求和技术迭代情况怎样？
    - 核心回答：2026年是超节点元年，目前处于熟悉和验证期，需求主要由阿里、字节、腾讯三家头部CSP牵引，阿里已发布磐久2.0并启动大规模招标。
    - 详细说明：
        - 超节点主要解决万亿级参数大模型的并行计算准确性、HBM GPU互联及Scale-up通信卡点。
        - 阿里磐久2.0采用平头哥PPU 1.5，2026年招标总量4500柜，单柜128卡（两个64卡独立系统），预估单柜成本2200多万，总投资近千亿。
        - 中标分布：华勤1500柜，华信1500-2000柜，浪潮1000柜，联想500柜。
        - 交付周期约6个月，预计2027年初陆续交付；下一代Infra 3.0将采用PPU 1.7，预计2026年12月招标8000柜，单卡金额可能翻倍。
- 问题 2：字节和腾讯在超节点方面的布局和采购情况如何？
    - 核心回答：字节采用自研推理芯片配合寒武纪训练芯片，腾讯采用自有投资GPU方案，两者均在2026年进行小规模验证，大规模上量在2027年。
    - 详细说明：
        - 字节自研“Megachain”推理芯片（功耗250-300W），首期超级变和华山共交付约500柜，单柜600多万；真正上量的“广东上”项目规划2.5万柜，资本开支约2500亿，但近期因ROI质疑可能存在砍单。
        - 字节通过寒武纪补充GPU整机柜验证，阿里已暂停引入寒武纪因报价偏高，字节仍在导入。
        - 腾讯自有GPU方案，2026年招标约4000柜，单柜64卡，单柜成本1000多万，总开支400多亿，华勤、曙光、宁畅、浪潮中标。
- 问题 3：百度及其他厂商在超节点领域的表现如何？
    - 核心回答：百度天池方案开放，多家厂商可参与，但百度在整机柜领域相对落后；其他非头部CSP和运营商市场主要由深腾（华为）、曙光等占据。
    - 详细说明：
        - 百度天池标准开放，华三发货两三百柜，中兴发货三五百柜，整体规模较小。
        - 运营商和党政市场主要是深腾的天下，华为和海光深耕其中，其他厂商进入困难。
- 问题 4：超节点整机柜相比传统8卡/16卡服务器，在性能和成本上有何具体提升？
    - 核心回答：整机柜在运行大模型业务时性能提升30%-50%，TCO显著优于传统架构，但存在故障率高、系统工程复杂的问题。
    - 详细说明：
        - 传统8卡需通过光模块网络调度，数据传送慢，GPU等待时间长；整机柜将64卡组在一个系统内，减少通信开销。
        - 性能差异：相同业务下，64卡整机柜效率比8台8卡服务器提升至少30%-50%。
        - 劣势：直通率和故障率较高，尚未达到完全稳定的生产加工状态，目前主要在公共云业务中使用，私有云仍偏向传统部署。

- 问题 5：整机柜的运营成本相比以前有多大提升？ODM厂商的报价策略是怎样的？
  - 核心回答：ODM厂商为争夺市场份额，报价普遍低于核算成本5%-10%，处于亏损状态，主要依靠政府补贴或其他业务弥补。
  - 详细说明：
    - ODM厂商（如浪潮、华勤、中兴等）对阿里、字节、腾讯的报价均为亏损，例如核算2500万，报价可能为1800-2000万。
    - 亏损幅度约5%-10%，部分厂商如中兴有南京市政府补贴和税收返点支持。
    - 互联网客户的运营成本（如跑千问、豆包的收入）属于内部测算，ODM厂商无法获取。
- 问题 6：超节点机柜中各组件的定价权归谁？ODM厂商的利润来源是什么？
  - 核心回答：CSP厂商采用AVP（指定供应商采购）模式，核心高价值部件价格由客户锁定，ODM厂商仅能赚取加工费和非指定部件的微薄利润。
  - 详细说明：
    - 以2200万的柜子为例，ODM自行采购定价的部分仅约400多万，其余1800多万为指定采购（如冷板、CPU、GPU等），价格由阿里等客户谈好。
    - ODM利润来源：普通线缆、PCB、小风扇等非指定部件的采购差价，以及加工费、测试费、维保费。
    - 由于核心值钱部件控不住，导致整体报价亏损。
- 问题 7：各家ODM厂商（如超级变、浪潮、新华三）在自有品牌超节点方案上有何差异？
  - 核心回答：除互联网定制外，自有品牌超节点销量极少，技术路线基本跟随北美和英伟达，未来将引入光互联技术。
  - 详细说明：
    - 华山与百度合作S8000，联想发布Sky40卡，但2026年预测销量仅几十柜，主要买家仍是互联网大厂。
    - 技术演进一致，下一代将涉及光互联（硅光）。
- 问题 8：党政和信创市场对超节点的需求及国产化要求如何？
  - 核心回答：党政和运营商市场主要由华为、海光、曙光占据，对国产GPU和器件国产化率有明确指标（如80%），需求更多出于政治任务和验证，而非纯商业驱动。
  - 详细说明：
    - 信创要求国产器件达标率，整机柜领域华为深腾950/9910已销售750套，优势明显。
    - CSP（阿里、字节）的需求增长前景远超运营商和党政，因其有真实的AI业务场景赋能。
- 问题 9：明年超节点出货的节奏及限制因素有哪些？HBM和GPU供给情况如何？
  - 核心回答：HBM和国产GPU产能是主要卡点，预计2028年供需大幅缓解；目前市场缺卡

，CSP资本开支受ROI和现金流压力影响可能放缓。
    - 详细说明：
        - HBM依赖国外两家厂商，国产化进度慢，制约平头哥、寒武纪等厂商。
        - 国产GPU产能有限（7nm工艺年产能200-300万卡），中小厂商生存艰难。
        - 2028年后产能过剩可能导致第三梯队GPU厂商更难生存。
        - CSP厂商现金流紧张，AI变现能力未完全验证，可能降低资本开支。

- 问题 10：HBM和GPU价格波动对ODM毛利率有影响吗？未来毛利率稳定在什么水平？

    - 核心回答：核心部件价格由客户锁定，对ODM毛利无直接影响；短期内ODM在互联网业务上仍将维持亏损状态，靠其他业务弥补。
    - 详细说明：
        - 核心部件（卡、冷板等）均为AVP指定采购，ODM不参与定价。
        - 中兴财报显示销售额猛增但利润下滑，因重仓阿里业务亏损较大（可能亏20个点），其他厂商亏5-10个点。
        - 这是一个“后勤循环”，做得越多亏得越多，但不做就无法进入供应商圈子。
        - 只有供应商（冷板、电源等）赚钱，ODM处于中间亏损环节。

- 问题 11：ODM厂商是否会参与算力运营或服务衍生业务？

    - 核心回答：不会，ODM厂商擅长卖设备，不擅长重资产的算力租赁运营，该领域由数据中心运营商或资本方主导。
    - 详细说明：
        - 算力租赁需要巨额资金（单个数据中心上百亿），ODM利润薄（几十亿），不具备规模效应和边界效应。

- 问题 12：万卡集群的技术难点及未来技术演进方向是什么？

    - 核心回答：万卡集群技术上可行（二层网络嵌套），但业务场景尚未完全需要；未来演进方向包括800V供电、液冷升级、硅光互联及带宽提升。
    - 详细说明：
        - 单层Scale-up最大1024卡，万卡需二层网络，技术无瓶颈，但业务接受度待验证。
        - 供电：从54V升至800V，需配备储能电容。
        - 散热：GPU功耗升至1500-3500W，推动微通道、液态金属等冷板技术。
        - 互联：带宽从112G升至224G/448G，Switch芯片升级至1.6T/3.2T，硅光互联将在2028年落地。

- 问题 13：目前训练和推理在整机柜中的比例是多少？

    - 核心回答：推理需求远大于训练，阿里采购大量NV PCIe卡用于推理，整机柜主要用于高精度训练。
    - 详细说明：
        - 阿里今年采购约12万台8卡PCIe服务器（约100万张卡）全部用于推理。

    - 整机柜（64/128卡）主要用于十万亿级大模型训练，推理一般用不到这么高端的配置。

- 问题 14：政策补贴对超节点需求有拉动吗？国产卡在推理市场的现状如何？
    - 核心回答：政策有一定拉动，但主要还是商业驱动；国产卡在推理市场占比不高，头部模型厂商多用NV卡或自研卡，寒武纪主要绑定字节。
    - 详细说明：
        - 超节点部署在内蒙等地，TCO优势明显，后续会逐步替代8卡训练。
        - 国产卡现状：生成式AI第一梯队（如阿里平头哥）不对外卖；寒武纪主要客户是字节和阿里，优先保字节；百度昆仑芯主要供腾讯。
        - 寒武纪新卡性能翻倍，单价30多万，因缺货价格坚挺。
        - 第三梯队（摩尔、天数等）性能偏弱，主要在实验室或中小项目使用。
        - 国内大模型厂商（Kimi、DeepSeek等）推理多用NV阉割版PCIe卡，训练用国产高端卡。
        - 未来趋势：产能释放后，头部GPU厂商将切入专用推理芯片市场，第三梯队生存空间更小。

高价值表达

- 关于ODM亏损逻辑
    - 观点摘要：ODM厂商在互联网超节点业务中处于“做得越多亏得越多”的困境，但为了进入供应链圈子不得不参与。
    - 原文表达：你可以理解为它目前处在一个后勤循环的状态...做的越多，亏损的越多，不做也不行。
- 关于技术演进确定性
    - 观点摘要：超节点架构已清晰，未来几年将是供电、散热和互联技术的线性升级，硅光是关键突破点。
    - 原文表达：架构基本上就很清楚，供电八百，然后冷板...GPU肯定会功耗升到三千或者三千五，然后剩下的就是光硅光出来。

分歧与不同观点

- 关于阿里是否导入寒武纪
    - 专家观点：阿里已暂停导入寒武纪，因为整体报价偏贵，高于拼多多（此处疑为口误，应指其他竞品或内部成本线），持慎重态度。
    - 潜在市场认知：部分投资者可能认为阿里会广泛采用国产芯片，但实际商业决策中成本权重极高。

未回答与待确认

- 具体的TCO测算数据：专家提到整机柜TCO优于8卡，但未提供具体的节省百分比或金额数据

，仅表示“显著”。
- 字节砍单的具体比例：专家提到字节可能有砍单情况，但未给出具体砍单数量或比例。
- 3D堆叠技术细节：专家对寒武纪等厂商是否采用3D堆叠技术表示具体细节不了解，仅确认了CoWoS等先进封装的使用。

AI洞察

- 产业链利润分配极度不均：超节点热潮下，利润主要集中在上游核心部件供应商（GPU、HBM、冷板、电源）和CSP厂商手中，中游ODM组装厂沦为“代工苦力”，甚至需贴钱换市场，这种商业模式不可持续，未来可能引发行业整合或ODM厂商退出该细分领域。
- 技术迭代倒逼供应链重构：从风冷到液冷、从铜互联到硅光、从低压到800V高压，超节点的技术演进不仅是性能提升，更是对供应链能力的重新洗牌，具备垂直整合能力（如自研芯片、自研液冷）的CSP厂商话语权将进一步增强。
- 推理市场被低估：市场焦点多在训练侧的大模型竞赛，但数据显示推理侧的硬件需求量（尤其是PCIe卡）远超训练侧，且国产芯片在推理侧的渗透率低于预期，NV的存量优势和生态壁垒在推理端依然坚固。

章节

- 00:00:11 国内超节点市场概况与CSP需求
    - 专家介绍2026年为超节点元年，目前主要由阿里、字节、腾讯等头部CSP客户牵引。详细分析了阿里磐久2.0及下一代Infra 3.0的招标规模与成本，字节的推理芯片布局及潜在砍单风险，以及腾讯的整机柜招标情况。指出当前处于小批量导入验证阶段，真正放量预计在2027年。
- 00:11:22 超节点性能优势与OEM厂商盈利困境
    - 对比整机柜与传统8卡/16卡在并行计算效率上的差异，指出整机柜在TCO上具有显著优势但故障率较高。深入剖析OEM厂商在CSP业务中的亏损现状，解释AVP模式下核心部件由客户指定采购，ODM仅赚取微薄加工费甚至亏本报价以进入供应链圈的商业模式。
- 00:24:46 技术演进趋势与供应链瓶颈
    - 探讨HBM供应短缺对GPU产能的制约，预计2028年供需缓解。分析未来技术演进方向，包括800V高压供电、液冷技术升级、硅光互联以及GPU功耗提升带来的挑战。指出推理需求目前大于训练需求，且国产GPU厂商在产能释放后将面临更激烈的市场竞争。
- 00:44:13 国产芯片现状与互动问答
    - 回答关于政策补贴、国产GPU在推理与训练场景的应用比例等问题。明确阿里、字节等大厂在推理侧大量使用NV阉割版卡，训练侧依赖寒武纪、平头哥等国产高端芯片。讨论国产厂商未来向专用推理芯片发展的趋势，以及3D堆叠技术在芯片设计中的应用前景。